

MODUŁ 5 - AI MASTERY

Sztuczna inteligencja (AI) stanowi fundament nowoczesnych technologii, a jej sercem jest **Uczenie Maszynowe (Machine Learning - ML)**. Jest to dziedzina, która umożliwia komputerom naukę i podejmowanie decyzji na podstawie dostępnych danych, eliminując konieczność stosowania sztywno zaprogramowanych reguł.

Proces ten opiera się na trzech głównych metodach:

- **uczeniu nadzorowanym** (system otrzymuje dane wejściowe wraz z oczekiwanymi wynikami)
- **uczeniu nienadzorowanym** (komputer samodzielnie identyfikuje wzorce bez wskazówek)
- **uczeniu ze wzmocnieniem**, w którym system uczy się poprzez próby i błędy, otrzymując nagrody za poprawne działania i kary za błędne.

Ewolucja tej dziedziny doprowadziła do powstania **Generatywnej AI (GenAI)**, będącej podzbiorem uczenia maszynowego. Istnieje kluczowa różnica funkcjonalna między tymi technologiami: tradycyjne ML koncentruje się na analizie danych historycznych, identyfikacji wzorców, klasyfikacji i predykcji, podczas gdy GenAI skupia się na tworzeniu zupełnie nowych treści, takich jak tekst, obrazy, dźwięk czy kod. Wybór odpowiedniej technologii zależy od charakteru problemu i zasobów organizacji.

Cecha	Uczenie Maszynowe (ML)	Generatywna AI (GenAI)
Zakres i cel	Konkretne, dobrze zdefiniowane zadania (klasyfikacja, predykcja, optymalizacja).	Złożone, wielowymiarowe zagadnienia wymagające interpretacji i tworzenia treści.
Rodzaj danych	Dane ustrukturyzowane, wymagające starannego przygotowania.	Dane mniej uporządkowane (tekst, obrazy), większa elastyczność.
Czas wdrożenia	Przewidywalny; zazwyczaj od 3 do 6 miesięcy.	Bardziej wymagający proces; zazwyczaj od 6 do 12 miesięcy.
Zespół	Data Scientist, Inżynier Danych.	Zespół interdyscyplinarny (Inżynier AI, Architekt, Specjalista ds. danych).

W praktyce biznesowej obie te dziedziny mogą być komplementarne. Przykładowo, w finansach ML może prognozować trendy rynkowe, a GenAI na tej podstawie generować przystępny raport dla klienta. Podobnie w medycynie ML analizuje sygnały medyczne, a GenAI tworzy klarowne podsumowanie dla lekarza.

Skuteczność każdego modelu AI jest bezpośrednio uzależniona od **jakości danych**, na których jest trenowany. Wysoka jakość danych definiowana jest przez sześć kluczowych wymiarów:

- **Dokładność**: dane muszą wiernie odzwierciedlać rzeczywistość.
- **Spójność**: jednolitość informacji w różnych systemach i źródłach.
- **Aktualność**: odzwierciedlenie bieżącej sytuacji rynkowej.
- **Kompletność**: posiadanie wszystkich niezbędnych informacji bez luk.
- **Unikalność**: brak duplikatów fałszujących statystyki.
- **Ważność**: zgodność z przepisami prawa i normami branżowymi.

Niska jakość danych prowadzi do błędnych prognoz i strat finansowych. Aby temu zapobiec, stosuje się **czyszczenie danych** (eliminację błędów i duplikatów) oraz **ograniczanie szumu**, czyli usuwanie nieistotnych informacji zakłócających analizę. Wdrożenie polityki zarządzania danymi powinno obejmować określenie ról, standardów oraz procedur monitorowania jakości w czasie rzeczywistym. W sytuacjach braku wystarczającej ilości realnych informacji rozwiązaniem są **dane syntetyczne**, generowane przez AI na podstawie struktury danych oryginalnych. Równie istotne jak jakość jest bezpieczeństwo informacji. Istnieje szereg metod pozwalających na analizę przy jednoczesnej **ochronie prywatności**.

Podstawowe techniki anonimizacji danych:

- **Maskowanie danych:** zastępowanie wrażliwych informacji losowymi wartościami.
- **Pseudonimizacja:** zastępowanie identyfikatorów pseudonimami.
- **Dodawanie szumów:** celowe wprowadzanie zakłóceń. <u>Im większy szum, tym lepsza ochrona prywatności, ale mniejsza dokładność wyników</u>.

Zaawansowane techniki anonimizacji danych:

- **Prywatność różnicowa:** analiza danych bez ujawniania informacji o pojedynczych osobach; dodaje się losowy szum do danych np. zmiana tak na nie
- **Federacyjne uczenie maszynowe:** model uczy się bezpośrednio na urządzeniach użytkowników, bez przesyłania ich danych na centralny serwer, co wymaga dużej mocy obliczeniowej.
- **Obliczenia homomorficzne:** wykonywanie operacji na danych zaszyfrowanych bez konieczności ich odszyfrowywania.
- **Obliczenia wielostronne:** analiza wspólnych danych przez wiele stron, gdzie każda widzi tylko wynik końcowy, bez dostępu do danych surowych innych uczestników.

Ocena zakresu i wysokość ryzyka dla Organizacji

Potraktuj osobno zakres ryzyka (czyli jak szeroko ono występuje) od wysokości (jak dotkliwe mogą być konsekwencje naruszenia ochrony danych osobowych).

Zaproponuj środki mitygujące ryzyko naruszenia prawa, w szczególności zastosowanie technicznych środków do anonimizacji danych osobowych w materiałach wizualnych.

W szczególności zwróć uwagę aby środki te były racjonalne i proporcjonalne, biorąc pod uwagę ilość danych osobowych, stopień ich wrażliwości oraz aktualne możliwości technologii do anonimizacji.

Zastanów się na którym etapie procesu powinna następować anonimizacja. Natychmiast u źródła? Po przekazaniu danych do centralnego serwera? Przed udostępnieniem danych na zewnątrz podmiotom trzecim? Które z tych rozwiązań powinieneś wybrać z punktu widzenia zachowania adekwatnej dokładności anonimizacji, dostępności technicznych środków, ekonomicznej wykonalności oraz zaspokojenia wymogów prawa?

[grafiki stockowe - Unsplash](#)

[strona do anonimizacji grafiki - picdefacer](#)

Rozwój rozwiązań AI nie musi wiązać się z pisanem kodu. Możemy wyróżnić trzy podejścia: **High-code** (pełna kontrola, pisanie od zera), **Low-code** (gotowe elementy z możliwością modyfikacji kodu np. Lang Chain - biblioteka kodów dla Pythona. Lang Flow - nakładka wizualna z blockami, Relevance AI, Wordware) oraz **No-code** ([Zapier](#) - łączy różne aplikacje i automatyzuje przepływ informacji między nimi, [Make \(dawniej: Integromat\)](#), [n8n](#) -

jest open source i można go uruchomić na własnym serwerze, [Bubble](#) - można tworzyć własne aplikacje od podstaw, [Adalo](#) - tworzenie aplikacji)

Inne: Google Vertex AI (dawniej Auto ML), Teachable Machine, Hugging Face Spaces, Runway ML, Microsoft Copilot Studio, Big ML, Cogniflow, Flowise AI, Hugging Face Auto Train

Podejście	Zalety	Wady
No-code	Najszybsze wdrożenie, intuicyjne, idealne do prototypowania.	Ograniczona elastyczność, zależność od twórców narzędzia.
Low-code	Szybsze niż High-code, łatwiejsza integracja z bazami danych.	Wymaga podstaw programowania.
High-code	Pełna kontrola, brak ograniczeń narzędziowych.	Czasochłonne, wysokie koszty i wymagane zaawansowane umiejętności.

Większość platform No-code opiera się na powtarzalnym procesie: importowaniu danych, automatycznym czyszczeniu i wykrywaniu zależności, wyborze modelu przez kreatora, symulacji działania oraz finalnym wdrażaniu poprzez integrację z systemami firmowymi. Interakcja z modelami AI, zwłaszcza językowymi, opiera się na **promptowaniu** – sztuce formułowania zapytań w celu uzyskania optymalnych rezultatów.

Zaawansowane techniki promptowania:

- **Łańcuch myśli (Chain of Thought):** skłonienie modelu do jawnego wypisania toku rozumowania przed podaniem odpowiedzi. Można to zrobić bez przykładów (**Zero-shot**) lub pokazując rozwiązany problem (**Few-shot**).
- **Rozbijanie/dekompozycja problemów (Problem Decomposition):** dzielenie złożonych zadań na mniejsze, łatwiejsze etapy rozwiązywane osobno.
- **Samodoskonalenie (Self-Refinement):** prośba o ocenę własnej odpowiedzi przez AI, wskazanie błędów i ich poprawę lub zmianę stylu na bardziej profesjonalny.
- **Łączenie wielu wyników (Ensembling) - samokonsystencja (self-consistency):** porównywanie odpowiedzi z różnych modeli lub uzyskanych różnymi technikami promptowania w celu zwiększenia wiarygodności.

RAG (Retrieval-Augmented Generation): system najpierw wyszukuje informacje w zewnętrznej bazie wiedzy (dokumenty firmowe, Wikipedia), a następnie generuje odpowiedź na ich podstawie, co drastycznie ogranicza halucynacje modelu. RAG składa się z dwóch głównych modułów: wyszukiwarki (retriever) - przyjmuje zapytanie użytkownika i przeszukuje bazę wiedzy + model językowy - dostaje on pytanie plus bazę wiedzy którą znalazł retriever.

Chunking (dzielenie na fragmenty) w kontekście sztucznej inteligencji (AI) i dużych modeli językowych (LLM) to proces dzielenia dużych zbiorów danych (dokumentów, tekstów, transkrypcji) na mniejsze, zarządzalne jednostki, tzw. chunki (porcje). Jest to kluczowy element technologii RAG, umożliwiający AI efektywne przeszukiwanie i analizowanie dokumentów. Stosuje się go, ponieważ modele językowe mają limit ilości tekstu, który mogą przetworzyć naraz.

Współczesna AI dąży do coraz większej autonomii i przejrzystości. Rozwijane są **autonomiczne systemy decyzyjne (Agentic AI)**, zdolne do działania bez ciągłej kontroli człowieka, oraz **multimodalne AI**, przetwarzające jednocześnie tekst, obrazy i dźwięk. W sektorach wysokiego ryzyka kluczowe stają się modele **Explainable AI**, które potrafią wyjaśnić przyczyny podjęcia danej decyzji w sposób zrozumiały dla ludzi.

Robotic AI - roboty wspierane AI

AI predykcyjne - Algorytmy prognozujące przyszłość na podstawie danych historycznych.

Zastosowania tych technologii są wszechobecne:

Medycyna: diagnozowanie chorób z obrazów (RTG, MRI), wykrywanie zmian chorobowych (Inspectra), projektowanie leków (Insilico Medicine).

Finanse: wykrywanie oszustw w czasie rzeczywistym, ocena ryzyka kredytowego, prognozowanie rynków.

Handel i E-commerce: sklepy bezkasowe (AmazonGo), personalizacja ofert, wirtualne przymierzanie produktów.

Przemysł i Produkcja: inteligentne roboty (Flippy), predykcyjne utrzymanie ruchu (Predictive Maintenance).

Prawo: automatyczna weryfikacja umów pod kątem zgodności z regulacjami.

Kreatywność i Edukacja: generowanie treści (Jasper AI, Copy.ai), personalizacja programów nauczania, wsparcie w pisaniu kodu (GitHub Copilot, Tabnine).

- Uczenie Maszynowe (ML) służy do predykcji i klasyfikacji, podczas gdy Generatywna AI (GenAI) tworzy nowe treści.
 - Jakość danych (dokładność, spójność, aktualność, kompletność) determinuje sukces wdrożenia AI.
 - Metody ochrony prywatności (np. federacyjne uczenie, obliczenia homomorficzne) pozwalają analizować dane bez ich udostępniania w formie surowej.
 - Technologie No-code i Low-code demokratyzują dostęp do AI, przyspieszając prototypowanie bez konieczności głębokiej wiedzy programistycznej.
 - Zaawansowane techniki promptowania (RAG, Chain of Thought) zwiększają wiarygodność i precyzję modeli językowych.
 - Explainable AI jest niezbędne w medycynie i finansach, aby zrozumieć proces podejmowania decyzji przez maszynę.
-

- Jaka jest podstawowa różnica między celem stosowania tradycyjnego ML a Generatywnej AI?
- Dlaczego w metodzie dodawania szumów występuje kompromis między prywatnością a dokładnością?
- W jaki sposób technika RAG (Retrieval-Augmented Generation) zapobiega zjawisku halucynacji w modelach AI?
- Czym różni się federacyjne uczenie maszynowe od obliczeń wielostronnych w kontekście przechowywania danych surowych?
- Jakie są główne zalety i ograniczenia podejścia No-code w porównaniu do High-code?
- Kiedy warto zastosować technikę promptowania "Łańcuch myśli" (Chain of Thought)?
- Jakie cechy decydują o tym, że dane są uznawane za wysokiej jakości?

AI Act (ROZPORZĄDZENIE PARLAMENTU EUROPEJSKIEGO I RADY (UE) 2024/1689 z dnia 13 czerwca 2024 r) - [link](#)

Europejski Inspektor Danych Osobowych (European Data Protection Supervisor) - [link](#)

Europejska Rada Ochrony Danych (EDPB – European Data Protection Board) - [link](#)

serwisów publikujących wiadomości z dziedziny ochrony danych osobowych - [GDPR](#)

katalogi kar nałożonych przez organy zajmujące się egzekwowaniem przestrzegania RODO (ang. GDPR): [Urząd Ochrony Danych Osobowych](#), [kancelarię prawną CMS Law-Tax-Future](#)

[Teachable Machine](#) - tworzenie modelu AI

[obiektyw Google](#) - rozpoznawanie obiektów